

Diferenças entre a Etapa Atual e a Proposta Inicial

Kaique Agostinho de Oliveira (RM: 550815) - 2TDSS

Cauã Couto Basques (RM: 97755) - 2TDSS

Thiago Gil (RM: 551211) - 2TDSPV

Contents

1	Introdução	2
2	Mudanças Significativas	2
3	Frameworks/Bibliotecas Python, APIs e Recursos Utilizados	3
4	Funcionamento dos Recursos/Ferramentas na Aplicação	4
4.1	Algoritmos de Machine Learning (ML)	4
5	Utilização de ML/IA no Desenvolvimento do Projeto	5

1 Introdução

Desde a concepção inicial do projeto até sua fase atual, várias evoluções e ajustes foram feitos para aprimorar a eficácia e a funcionalidade da solução proposta. Abaixo estão destacadas as mudanças significativas.

2 Mudanças Significativas

- a) **Adoção de Novos Algoritmos de ML/IA:** Na proposta inicial, tínhamos planejado utilizar algoritmos tradicionais de machine learning, como regressão linear e árvores de decisão. No entanto, após uma análise mais aprofundada e considerando a complexidade dos dados e das interações com os clientes, optamos por incorporar algoritmos mais avançados, como redes neurais convolucionais (CNNs) e redes neurais recorrentes (RNNs), para lidar com a análise de dados não estruturados, como feedbacks de clientes e dados de chat.
- b) **Integração de Novas APIs:** Originalmente, planejamos integrar algumas APIs de processamento de linguagem natural (NLP) para análise de sentimentos e extração de entidades. No entanto, durante o desenvolvimento, reconhecemos a importância de expandir as capacidades da PersonalAssist para melhor atender às necessidades dos usuários. Como resultado, estamos incorporando APIs de reconhecimento de intenções para aprimorar a compreensão das solicitações dos clientes e facilitar interações mais naturais com o assistente virtual. Essa integração diversificada não apenas enriquece a funcionalidade da plataforma, mas também eleva sua acessibilidade e usabilidade, proporcionando uma experiência mais fluida e eficaz para os usuários.
- c) **Expansão dos Recursos Previstos:** Inicialmente, nossa proposta estava focada principalmente em fornecer assistência virtual inteligente e análise de dados para otimização de campanhas de marketing. No entanto, à medida que exploramos as capacidades da IA e consideramos o feedback inicial dos usuários, decidimos expandir os recursos da PersonalAssist. Agora, estamos incluindo funcionalidades adicionais, como recomendações personalizadas de conteúdo com base nas preferências dos clientes e suporte a múltiplos canais de comunicação, como e-mail, chat e redes sociais.

3 Frameworks/Bibliotecas Python, APIs e Recursos Utilizados

- a) **TensorFlow e PyTorch (Deep Learning):** Ambos são frameworks de código aberto amplamente utilizados para desenvolver e treinar modelos de redes neurais profundas.
- b) **Scikit-learn (Machine Learning):** É uma biblioteca eficiente e simples para aprendizado de máquina em Python, oferecendo uma variedade de algoritmos e ferramentas para modelagem preditiva.
- c) **NLTK (Natural Language Toolkit) e spaCy (Processamento de Linguagem Natural):** São bibliotecas populares para processamento de linguagem natural em Python, oferecendo uma ampla gama de ferramentas para análise de texto, tokenização, lematização, entre outros.
- d) **Flask (Desenvolvimento Web):** É um microframework web leve para Python, adequado para construir APIs RESTful e aplicações web simples e escaláveis.
- e) **Django (Desenvolvimento Web):** É um framework web de alto nível para Python, que fornece uma estrutura robusta e completa para desenvolvimento rápido de aplicações web.

4 Funcionamento dos Recursos/Ferramentas na Aplicação

4.1 Algoritmos de Machine Learning (ML)

a) Treinamento e Uso de Modelos de Recomendação:

- **Processo de Treinamento:** Os dados históricos de interação do cliente, como histórico de compras e preferências, serão utilizados para treinar modelos de recomendação, como filtragem colaborativa ou baseada em conteúdo.
- **Uso na Aplicação:** Quando um cliente acessa a plataforma, o modelo de recomendação é acionado para sugerir produtos ou serviços com base em seu perfil e comportamento passado.

b) Análise de Sentimentos e Feedbacks de Clientes:

- **Processo de Treinamento:** Utilizando técnicas de processamento de linguagem natural (NLP), como análise de sentimento, os dados de feedback dos clientes são analisados e categorizados em sentimentos positivos, negativos ou neutros.
- **Uso na Aplicação:** Essa análise de sentimento permite à PersonalAssist compreender as opiniões e emoções dos clientes, adaptando suas respostas e recomendações de acordo.

c) Integração de APIs Externas:

- **Integração com Redes Sociais para Análise de Sentimentos:**
 - **Funcionamento:** APIs de redes sociais, como a API do Twitter, são integradas à PersonalAssist para coletar e analisar posts e comentários dos clientes.
 - **Processamento de Dados:** Os dados coletados são processados utilizando técnicas de NLP para extrair sentimentos e identificar tendências em relação aos produtos ou serviços oferecidos pela empresa.
 - **Utilização na Aplicação:** Essa análise de sentimentos proveniente das redes sociais complementa a análise interna dos feedbacks dos clientes, fornecendo uma visão mais abrangente da percepção da marca e dos produtos no mercado.

5 Utilização de ML/IA no Desenvolvimento do Projeto

a) Previsão de Comportamento do Cliente:

- **Algoritmo de Árvores de Decisão:** Utilizado para segmentação de clientes com base em dados demográficos, comportamentais e histórico de compras.

b) Análise de Sentimentos:

- **Redes Neurais Recorrentes (RNNs) com LSTM:** Empregadas para análise de sentimentos em feedbacks de clientes e posts em redes sociais.

c) Otimização de Campanhas de Marketing:

- **Algoritmo de Aprendizado por Reforço:** Utilizado para otimizar o retorno sobre o investimento (ROI) em campanhas de marketing, ajustando dinamicamente os parâmetros com base no feedback em tempo real.

d) Exemplo de Integração de Algoritmos:

- **Pipeline de Processamento de Dados:** Utiliza uma combinação de técnicas de pré-processamento de dados, como tokenização, remoção de stopwords e vetorização, antes de alimentar os dados nos modelos de ML.